# 数据结构

夏天
xiat@ruc.edu.cn

中国人民大学信息资源管理学院

# 字符串

计算机非数值处理的对象经常是字符串数据。如文本检索、文本聚类、文本理解等。

- 串的定义及表示
- 串的模式匹配

# 串 (String) 的定义

- 串是由零个或多个任意字符组成的字符序列。它也是一种特殊的线性表，其数据元素仅由一个字符组成，而且它通常是作为一个整体来处理。
  例：s="Renmin University"，s 是串名，Renmin University 为串值，其中一个个的字符称为串的元素。
- 请思考如何实现上述串的存储？

# 字符串的存储

- 顺序存储: 用一组地址连续的存储单元存储串值中的字符序列。
- 链式存储: 考虑到存储密度，可以按块分配。
- 在 C++/Java 等语言中，String 就是字符串。在 C 语言中没有 string 类型变量，字符串用字符数组表示。

# 串的模式匹配

- 设 s 和 t 是给定的两个串，在主串 s 中寻找等于子串 t 的部分的过程称为模式匹配，t 也称为模式。
- 如果在 s 中找到等于 t 的子串，则称匹配成功，返回 t 在 s 中的首次出现的存储位置，否则匹配失败。
- 例：

  s="ababcabcacbab"

  t="abcac"

# 简单的模式匹配

s="ababcabcacbab"

t="abcac"

- Brute-Force 算法

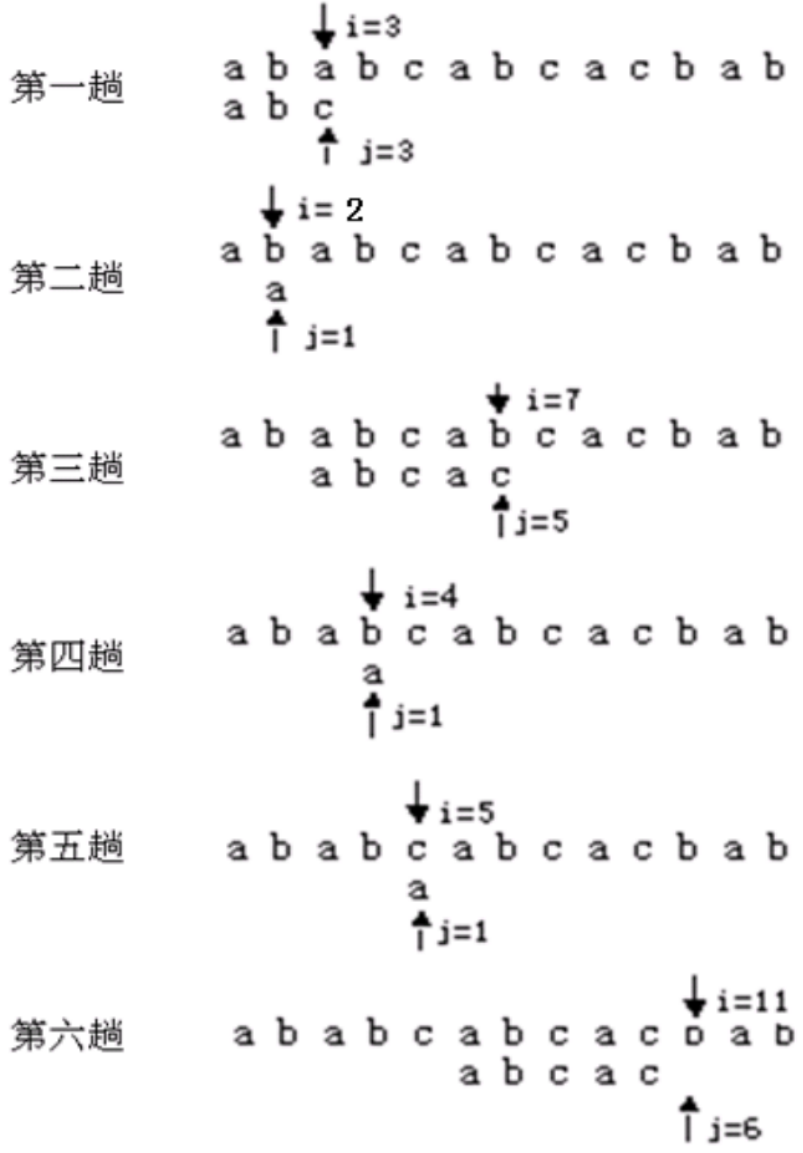

# BF 算法时间复杂度分析

- 设串 s 长度为 n，串 t 长度为 m。匹配成功的情况下，考虑两种极端情况。
  - 在最好情况下，即每趟不成功的匹配都发生在第一对字符比较时。
  - 例如：s= “aaaaaaaaaabc”，t= “bc”，设匹配成功发生在 $s_i$ 处。
  - 在前面 i-1 趟不成功的匹配中共比较了 i-1 次，第 i 趟成功的匹配共比较了 m 次，所以总共比较了 i-1+m 次。
  - 所有匹配成功的可能共有 n-m+1 种，设从 si 开始与 t 串匹配成功的概率为 $p_i$，在等概率情况下 $p_i = 1/(n-m+1)$，因此最好情况下平均比较的次数是：

$$\sum_{i=1}^{n-m+1} p_i \times (i-1+m) = \sum_{i=1}^{n-m+1} \frac{1}{n-m+1} \times (i-1+m) = \frac{(n+m)}{2}$$

  - 即最好情况下的时间复杂度是 $O(n+m)$

- 在最坏情况下，即每趟不成功的匹配都发生在 $t$ 的最后一个字符。
- 例如：$s=$“aaaaaaaaaaab”，$t=$“aaab”，设匹配成功发生在 $s_i$ 处.
- 在前面 $i-1$ 趟匹配中共比较了 $(i-1)\times m$ 次，第 $i$ 趟成功的匹配共比较了 $m$ 次，所以总共比较了 $i\times m$ 次，因此最坏的情况下平均比较的次数是：

$$\sum_{i=1}^{n-m+1} p_i \times (i \times m) = \sum_{i=1}^{n-m+1} \frac{1}{n-m+1} \times (i \times m) = \frac{m \times (n-m+2)}{2}$$

- 即最坏情况下的时间复杂度是 $O(n\times m)$

**为什么 BF 算法时间性能低？**

在每趟匹配不成功时存在大量回溯 (每次移动一位开始新的比较)

# 改进算法

- 改进算法的目的是在每一趟匹配过程中出现不匹配时，向右“滑动”尽可能远的一段距离后，继续进行比较。那么，应当滑动多远呢？这正是各个算法各显神通之处！
- KMP 算法: 由 D. E. Knuth，J. H. Morris 和 V. R. Pratt 同时发现
- Boyer-Moore 算法

# KMP 算法

利用已经得到的“部分匹配”的结果将模式向右滑动